Detecção de diabetes com Aprendizado de Máquina



Mineração de Dados

Danyella Alves
Julia Ferreira
Silvana Luz



Introdução e **definição do problema**

- O diabetes é uma doença crônica cujo diagnóstico precoce é importante para reduzir complicações. Este projeto utiliza técnicas de aprendizado de máquina para classificar pacientes em dois grupos: Controle (0) ou Diabetes (1), a partir de dados clínicos e laboratoriais.

Objetivo: treinar e comparar três algoritmos de classificação para identificar possíveis casos de diabetes.

Dados **utilizados**

Foram utilizados dois conjuntos de dados fornecidos pelo professor:

Treino

540 pacientes com classificações conhecidas

Teste

312 pacientes sem classificação conhecida

Variável-alvo

class, indicando Controle (0) ou Diabetes (1)

Atributos

idade, pressão arterial, IMC, glicose, insulina, HbA1c e indicadores laboratoriais

Pré-processamento **dos dados**

Remoção de colunas irrelevantes

ID; PATIENT_CODE; EXAM_DATE; BIRTH_YEAR; COLLECTION_SITE; LAB_DEVICE.

Divisão dos dados

80% foram destinados ao treinamento e 20% à validação.

Normalização por Z-score

Foi aplicada a normalização por Z-score, implementada no scikit-learn pelo StandardScaler. Essa técnica transforma os valores de cada coluna para que todos fiquem na mesma escala: média zero e desvio padrão um



Estratégia **Treinamento e Validação**

Validação Cruzada 5-fold (Cross-Validation)

Em vez de usar a divisão treino/validação uma única vez (o que pode dar resultados aleatorios dependendo de quais pacientes caem em cada conjunto), usamos validação cruzada com 5 folds

Dividimos o conjunto de treino em 5 partes iguais (folds)

Repetimos o processo 5 vezes: em cada rodada, 4 folds sao usados para treino e 1 para validação

A metrica final é a MEDIA das 5 rodadas

Métrica utilizada: F1-Macro

Métricas de **Avaliação**

O desempenho dos modelos é avaliado por quatro métricas:

Recall Diabetes — Dos pacientes que realmente têm diabetes, quantos o modelo encontrou.

Recall Controle — Dos que são controle, quantos o modelo classificou corretamente.

Precisão — Dos pacientes que o modelo classificou como diabetes, quantos realmente têm.

F1-Macro — Média do F1 das duas classes, com o mesmo peso para cada uma

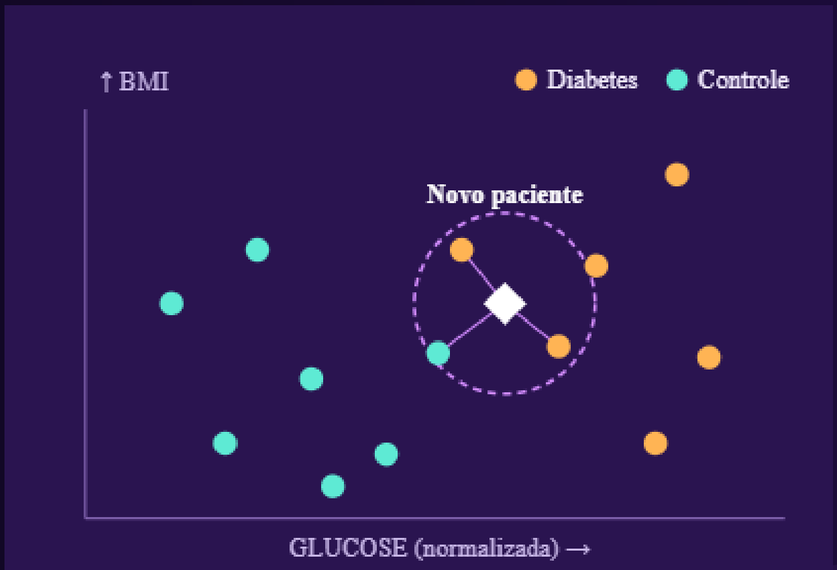
O F1-Macro é a principal métrica utilizada na comparação dos modelos

MODELO 1

KNN (K-Vizinhos Mais Próximos)

Como funciona

Classifica um paciente novo olhando para os K pacientes mais parecidos nos dados de treino e votando pela classe mais comum entre eles. A normalização é fundamental para evitar que variáveis com escalas maiores tenham influência excessiva no cálculo das distâncias.



K = 3: 2 de 3 vizinhos têm diabetes → Diabetes

Foram testados valores ímpares de 1 até 21, e escolhemos o que deu melhor F1-macro na validação cruzada.

Melhor resultado obtido com K = 5.

Métrica	Treino	Validação
Acurácia	0,8171	0,7593
Precisão	0,8349	0,7586
Recall (Diabetes)	0,8089	0,7857
F1-macro	0,8217	0,7719

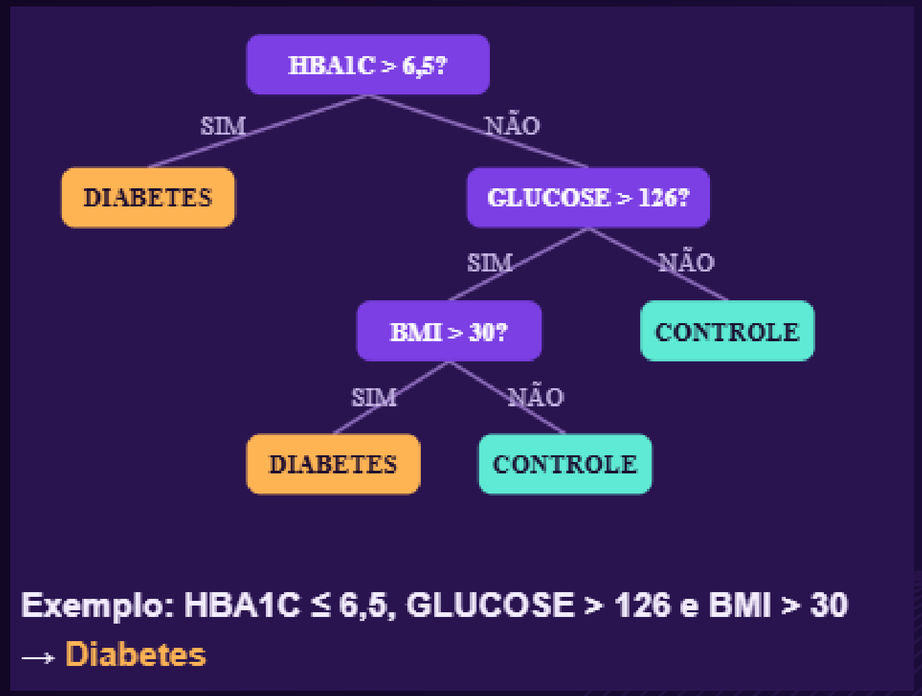
MODELO 2

Árvore De Decisão

Como funciona

Aprende uma série de regras do tipo: se glicemia maior que X e pressão maior que Y, então diabetes.

Hiperparametro max_depth: é a profundidade máxima da árvore, isto é, quantas perguntas em sequência ela pode fazer antes de dar uma resposta.



Exemplo: HBA1C ≤ 6,5, GLUCOSE > 126 e BMI > 30
→ Diabetes

Parametros Adicionais de Regularização

Parametros que evitam divisões com poucos exemplos:

- criterion
- min_samples_split
- min_samples_leaf
- random_state

Melhor resultado obtido com profundidade 3

Métrica	Treino	Validação
Acurácia	0,8935	0,8704
Precisão	0,9282	0,8500
Recall (Diabetes)	0,8622	0,9107
F1-macro	0,8940	0,8793

MODELO 3

Rede Neural MLP (Perceptron Multicamadas)

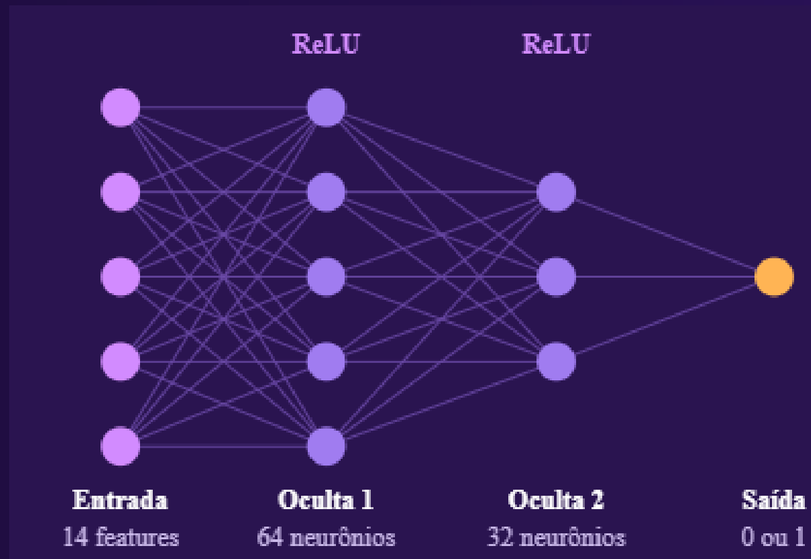
Como funciona

É uma rede com camadas de neurônios que aprende padrões mais complexos nos dados.

Otimizador Adam e Backpropagation: Ajusta os pesos para reduzir o erro, com taxa de aprendizado automática.

Regularização L2 (alpha): Pune pesos grandes contra overfitting: testamos alpha 0,001 e 0,01.

Função de Ativação ReLU: Se o sinal é negativo: saida = 0 (neuronio 'desligado'). Se o sinal é positivo: saida = x (neuronio 'ativo')



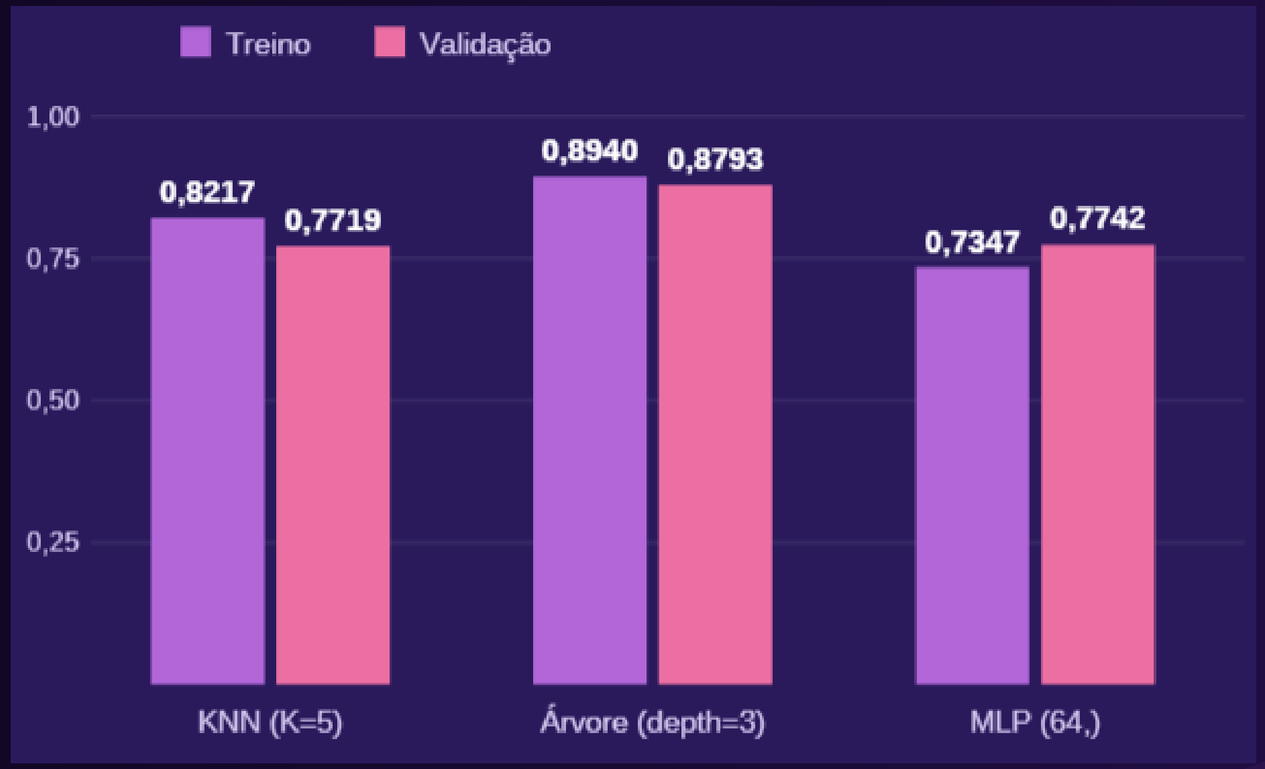
Testamos 6 arquiteturas, como (64,), (64, 32) e (64, 32, 16)

Melhor resultado obtido com camada (64,) e alpha = 0,001

Métrica	Treino	Validação
Acurácia	0,6991	0,7407
Precisão	0,6792	0,7059
Recall (Diabetes)	0,8000	0,8571
F1-macro	0,7347	0,7742

Comparação dos modelos

F1-macro (treino X validação)



Métricas na validação

Métrica	KNN	Árvore	MLP
Acurácia	0,7593	0,8704	0,7407
Precisão	0,7586	0,8500	0,7059
Recall (Diab.)	0,7857	0,9107	0,8571
F1-macro	0,7719	0,8793	0,7742

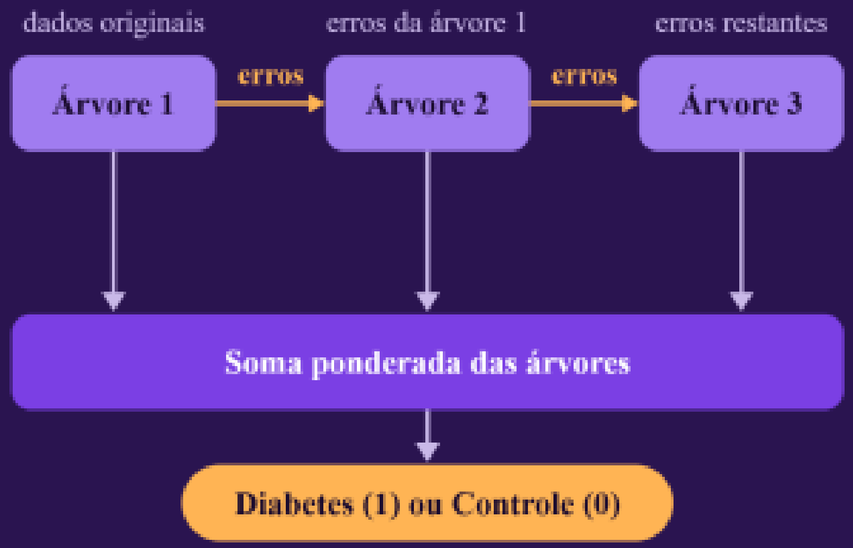
- A árvore teve o melhor F1-macro, no treino (0,8940) e na validação (0,8793).
- A MLP tem recall alto (0,8571), mas precisão menor: acerta casos de diabetes com mais alarmes falsos.

Gradient Boosting
Evolução dos Modelos

Exploramos o Gradient Boosting como uma evolução natural, buscando melhorar o desempenho da classificação.

Como funciona

Constrói várias árvores de decisão em sequência. A diferença para uma árvore simples é que cada nova árvore não aprende os dados do zero — ela aprende especificamente os erros que a árvore anterior cometeu. Assim, o modelo vai corrigindo os próprios erros ao longo das rodadas



Cada árvore corrige os erros da anterior

Submissão ao Kaggle
Ensemble



Score final no Kaggle

0,8119

F1-Macro

Ensemble = combinar vários modelos pela média das probabilidades, para reduzir o impacto dos erros de cada um.

Conclusão

Modelos obrigatórios

- KNN otimizado por F1-macro: 0.68678
- MLP otimizado por F1-macro: 0.66149
- Árvore de Decisão otimizada por F1-macro: 0.82106
- Ensemble KNN + Árvore + MLP (média de probabilidades, F1-macro): 0.81189

Gradient Boosting

Melhor resultado geral

- Gradient Boosting otimizado por F1-macro: 0.87155

Obrigada!

